期末实验一:基于华为云的大数据实时数据分 析综合实践

注:本实验的实验环境需以<mark>实验一的Hadoop环境</mark>和<mark>实验三的Zookeeper环境</mark>为基础进行搭建,如遇到 相关问题可以检查一下<mark>实验一和实验三</mark>的环境配置是否正确

一、local模式部署安装

1、实验介绍

local模式下的Flink部署安装只需要使用单台机器,仅用本地线程来模拟其程序运行,不需要启动任何进程,适用于软件测试等情况。这种模式下,机器不用更改任何配置,只需要安装JDK 8的运行环境即可。

2、实验目的

- 2.1 实现Flink的安装;
- 2.2 学会Flink的脚本启动;
- 2.3 使用Flink自带的单词统计程序进行测试。

3、实验步骤

3.1 上传安装包并解压

下载flink1.13.6并上传

下载地址:

https://archive.apache.org/dist/flink/flink-1.13.6/

由于flink在1.8版本后就不支持hadoop了,所以需要下载额外的包,下载路径如下:

https://mvnrepository.com/artifact/org.apache.flink/flink-shaded-hadoop-3-uber/3.1.1.7.2.1.0-327-9.0

https://mvnrepository.com/artifact/commons-cli/commons-cli/1.4

上传压缩包到服务器中,进行解压并将文件名改为flink

```
[root@zj-2023140696 ~]# tar -zxvf flink-1.13.6-bin-scala_2.11.tgz flink-1.13.6/
flink-1.13.6/lib/flink-shaded-zookeeper-3.4.14.jar flink-1.13.6/lib/flink-json-1.13.6.jar flink-1.13.6/lib/flink-table-blink_2.11-1.13.6.jar flink-1.13.6/lib/flink-csv-1.13.6.jar flink-1.13.6/lib/flink-dist_2.11-1.13.6.jar flink-1.13.6/lib/flink-dist_2.11-1.13.6.jar flink-1.13.6/lib/log4j-slf4j-impl-2.17.1.jar flink-1.13.6/lib/flink-table_2.11-1.13.6.jar flink-1.13.6/lib/log4j-core-2.17.1.jar flink-1.13.6/lib/log4j-core-2.17.1.jar flink-1.13.6/lib/log4j-api-2.17.1.jar flink-1.13.6/lib/log4j-api-2.17.1.jar flink-1.13.6/licenses/
flink-1.13.6/licenses/licenses/spizzled-slf4j flink-1.13.6/licenses/licenses/spizzled-slf4j flink-1.13.6/licenses/spizzled-slf4j flink-1.
```

3.2 配置全局环境变量

在.bashrc 配置文件中添加flink路径如下。

```
root@master:~# vim .bashrc

#FLINK
sexport FLINK_HOME=/root/flink
PATH=$FLINK_HOME/bin:$PATH
```

配置完.bashrc后再执行 source .bashrc, 让其生效

3.3 脚本启动Flink进程

配置好环境变量后就可以全局使用Flink的启动命令,直接以下命令。

注:在实验一中将node01节点hosts文件中127.0.0.1地址注释掉的同学在这一部分需要取消 node01节点中hosts文件的注释,保证localhost能被node01找到。

1 root@master:~# start-cluster.sh

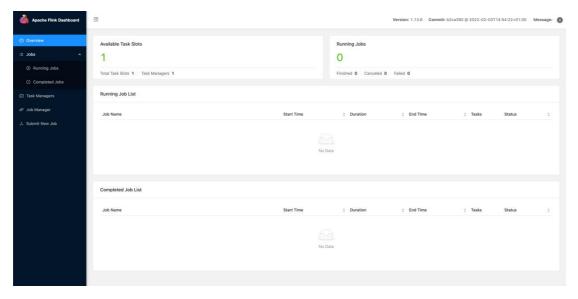
```
root@master:~# start-cluster.sh
Starting cluster.
Starting standalonesession daemon on host master.
Starting taskexecutor daemon on host master.
```

```
root@master:~# jps
16336 TaskManagerRunner
17931 Jps
16031 StandaloneSessionClusterEntrypoint
```

3.4 Web界面访问

成功启动两个进程后,访问8081端口即可访问Flink的Web管理界面。(其中node01替换为对应公网IP)

http://node01:8081/#/overview

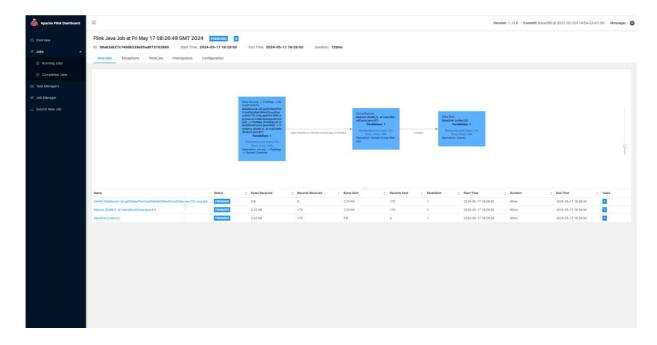


3.5 运行Flink自带的测试用例

```
root@master:~# cd /home/flink
  1
      root@master:~# bin/flink run
      examples/batch/WordCount.jar
root@master:~/flink# bin/flink run examples/batch/WordCount.jar --hostname localhost --port 9000
Executing WordCount example with default input data set.
Use --input to specify file input.
Printing result to stdout. Use --output to specify output path.
Job has been submitted with JobID 84ea8b58926bd3c6eb256ac28bb91197
Program execution finished
Job with JobID 84ea8b58926bd3c6eb256ac28bb91197 has finished.
Accumulator Results:
- 847a4c381561d6a0ac122f96ba38da40 (java.util.ArrayList) [170 elements]
(against,1)
(bare,1)
(bear,3)
```

3.6 查看统计结果

在Flink的Web管理界面进入Completed Jobs目录下,选择刚刚上交的任务,得到如下页面。



关闭local模式。

```
root@master:~# stop-cluster.sh

root@master:~# stop-cluster.sh

Stopping taskexecutor daemon (pid: 16336) on host master.

Stopping standalonesession daemon (pid: 16031) on host master.
```

二、standalone模式部署安装

1、实验介绍

使用standalone模式需要启动Flink的主节点JobManager以及从节点的TaskManager,具体的任务 进程划分见下表。

服务及IP	node01	node02	node03	node04
JobManager	是	否	否	否
TaskManager	是	是	是	是

2、实验目的

实现standalone模式下Flink进程的启动。

3、实验步骤

3.1 修改配置文件

停止node01服务器local模式下的进程后,修改配置文件。 在node01节点上执行以下命令,更改Flink配置文件。

```
1 root@master:~# cd flink/conf
2 root@master:~# vim flink-conf.yaml
```

jobmanager.rpc.address: master

```
# Common
# The external address of the host on which the JobManager runs and can be
# reached by the TaskManagers and any clients which want to connect. This setting
# is only used in Standalone mode and may be overwritten on the JobManager side
# by specifying the --host <hostname> parameter of the bin/jobmanager.sh executable.
# In high availability mode, if you use the bin/start-cluster.sh script and setup
# the conf/masters file, this will be taken care of automatically. Yarn/Mesos
# automatically configure the host name based on the hostname of the node where the
# JobManager runs.

jobmanager.rpc.address: master

# The RPC port where the JobManager is reachable.

jobmanager.rpc.port: 6123
```

更改workers配置文件。

1 root@master:~# vim workers

```
master
slave1
slave2
slave<mark>3</mark>
```

3.2 分发配置文件

将改好的文件分发给其他节点。docker的分发要先到宿主机中再进行分发

```
[root@zj-2023140696 ~]# docker cp flink slave1:/root
Successfully copied 354MB to slave1:/root
[root@zj-2023140696 ~]# docker cp flink slave2:/root
Successfully copied 354MB to slave2:/root
[root@zj-2023140696 ~]# docker cp flink slave3:/root
Successfully copied 354MB to slave3:/root
```

3.3 启动Flink集群

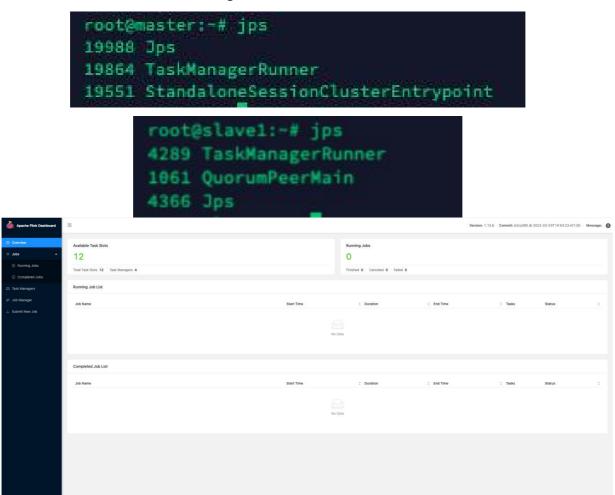
在node01上执行与local模式相同的命令启动Flink集群。

注:在实验第一部分中将node01节点hosts文件中127.0.0.1地址注释取消掉了,这一部分需要再次注释掉node01节点hosts文件中127.0.0.1地址,保证本机的TaskManager能够正确启动

1 root@master:~# start-cluster.sh

```
root@master:-# start-cluster.sh
Starting cluster.
Starting standalonesession daemon on host master.
Starting taskexecutor daemon on host master.
Starting taskexecutor daemon on host slavel.
Starting taskexecutor daemon on host slave2.
Starting taskexecutor daemon on host slave3.
```

进入Web管理页面(网址同第一章)能看到Task Managers和Task Slots数量为4,说明集群正确启动。(这里的task slots可以指定每个taskmanager中包含的数量,后文会提到,这里读者跟着上述步骤并未对其进行设计,故默认1个Task Managers中有1个Task Slots,所以此处应该是4个)



3.4 运行Flink自带测试用例

进行flink自带的测试用例的测试

1 root@master:~# bin/flink run examples/batch/wordCount.jar

```
root@master:-/flink# bin/flink run examples/batch/WordCount.jar
Executing WordCount example with default input data set.

Use --input to specify file input.

Printing result to stdout. Use --output to specify output path.

Job has been submitted with JobID 302f00b56e6d18a7f8ed91d240f4e48a

Program execution finished

Job with JobID 302f00b56e6d18a7f8ed91d240f4e48a has finished.

Job Runtime: 494 ms

Accumulator Results:

- b97fe0b7d8481c0ce4b306f37dc64657 (java.util.ArrayList) [170 elements]

(a,5)

(action,1)

(after,1)

(against,1)

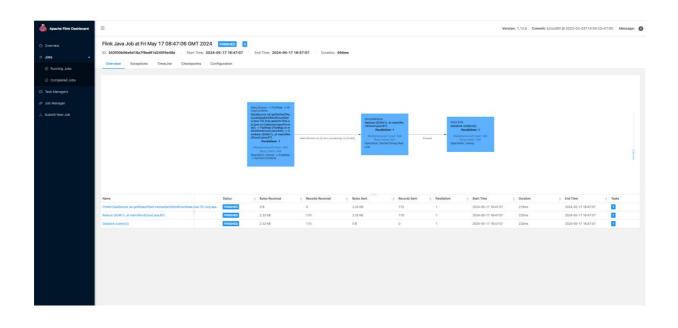
(all,2)

(and,12)

(arms,1)

(arrows,1)
```

在Web管理界面的Completed Jobs目录中,可以找到已经完成的任务。下图需要截屏作为得分点



三、Flink on Yarn模式

1、实验介绍

Flink任务也可以运行在Yarn上,将Flink任务提交到Yarn平台可以实现统一的任务资源调度管理, 方便开发人员管理集群中的CPU和内存等资源。

本模式需要先启动集群,然后再提交作业,接着会向Yarn申请资源空间,之后资源保持不变。如果资源不足,下一个作业就无法提交,需要等到Yarn中的一个作业执行完成后释放资源。

2、实验目的

- ◆ 完成Flink on Yarn模式的配置;
- ◆ 在Yarn中启动Flink集群;
- 以文件的形式进行任务提交。

3、实验步骤

3.1 修改yarn-site.xml配置文件

将上个实验启动的进程全部关闭。在node01上添加以下配置属性到该文件中进行修改。

然后将修改后的配置文件分发到其他节点上。之后启动HDFS和Yarn集群,使用start-all.sh

3.2 修改Flink配置文件

首先停止之前的Flink的standalone进程(使用jps命令获取对应进程号,然后直接kill掉对应进程,但要保留Hadoop进程)

在node01上执行以下命令修改FLink的配置文件。

◆ 修改flink-conf.yaml配置文件。

```
root@master:~# cd /flink/conf/
root@master:~# vim flink-conf.yaml 3

high-availability: zookeeper
high-availability.storageDir: hdfs://master/flink_yarn_ha high-availability.zookeeper.path.root: /flink-yarn
high-availability.zookeeper.quorum:
master:2181,slave1:2181,slave2:2181,slave3:2181
yarn.application-attempts: 10
```

•

修改masters配置文件

```
1 root@master:~# vim masters
2
3
4 zyw-2021140807-0001:8081
zyw-2021140807-0002:8081
```

master:8081 slave1:808<mark>1</mark>

在其他四个容器中也进行相同修改

同时将下面下划线的两个jar包分发到每个容器flink的lib中 (下载地址在实验手册开头)

```
root@master:-/flink/lib# ls commons-cli-1.4.jar flink-csv-1.13.6.jar flink-dist_2.11-1.13.6.jar flink-shaded-zookeeper-3.4.14.jar flink-dist_2.11-1.13.6.jar flink-shaded-zookeeper-3.4.14.jar flink-shaded-zookee
```

◆ 在各个节点上启动ZooKeeper。

具体启动方法细节请查看实验三,大概就是在已经配置过Zookeeper的前提下,输入zkServer.sh start 四个节点都要启动!输入启动命令后记得观察是否出现成功启动的提示,确保四个节点全部成功

3.3 在HDFS上创建文件夹

首先确保Hadoop集群已经运行,没有的话输入 start-all.sh 进行启动

输入 hadoop dfsadmin -safemode leave 解除潜在的安全模式

接下来创建文件夹、命令如下。

```
root@master:-# hdfs dfs -mkdir -p /flink_yarn_ha
2024-05-16 14:12:51,557 WARN util.NativeCodeLoader: Unable to load native-hadoop library for your platform... using builtin-java classes where applicable
root@master:-# hdfs dfs -ls /
2024-05-16 14:13:10,544 WARN util.NativeCodeLoader: Unable to load native-hadoop library for your platform... using builtin-java classes where applicable
found 3 items
drwxr-xr-x - root supergroup
drwxr-xr-x - root supergroup
drwxr-xr-x - root supergroup
drwxr-xr-x - root supergroup
0 2024-05-16 02:53 /tmp
drwxr-xr-x - root supergroup
0 2024-05-09 22:47 /user
```

3.4 在Yarn中启动Flink集群

在进行下一步的操作前,请大家务必做以下四步检

- 1. 主节点的/etc/hosts 文件中 127.0.0.1那一行**已经被**注释掉(其余三个节点无所谓),没有被注释掉的话建议重启四台服务器或者重启linux网卡,因为这个文件修改后不会立即生效,重启之后,再查看/etc/hosts 文件时,你可能会发现127.0.0.1那一行又没有被注释掉,不用慌,注释掉该行即可,不需要再次重启,接着做后面的三步即可
- 2. Hadoop集群已经启动,没有的话输入 start-all.sh 进行启动
- 3. 已经输入过hadoop dfsadmin -safemode leave 解除潜在的安全模式
- 4. 四个节点的Zookeeper已经全部启动成功

四步检查完毕后进行以下操作

在node01上执行以下命令,在Yarn中启动一个全新的Flink集群。可以使用--help查看yarn-session.sh的参数设置。

```
root@master:~# cd ...
1
      root@master:~# yarn-session.sh -n 2 -jm 1024 -tm
            10 14.14.08,236 LNPU org.apache.flink.shaded.curator4.org.apache.curator.framework.state.ConnectionStateManager [] - State change: CONNECTED 15 14:14:08,372 LNPO org.apache.flink.runtime.leaderretrieval.DefaultLeaderRetrievalService [] - Starting DefaultLeaderRetrievalService with Zookeepe valPath='/leader/rest_server_lock'}.
```

出现如上输出表明集群成功启动了。(如果出现持续滚动的信息,说明启动失败)

3.5 查看Yarn管理界面

访问Yarn的8088管理界面 http://node01:8088/cluster (此处node01应使用公网IP),可以看 到其中有一个应用,这是为Flink单独启动的一个Session。

下图需要截屏作为得分点 **Thedoo**p All Applications

3.6 提交任务

在master上提交测试任务。

```
cumulator Results:
2b4b9160975c71fad59b84bada2037fb (java.util.ArrayList) [170 elements]
```

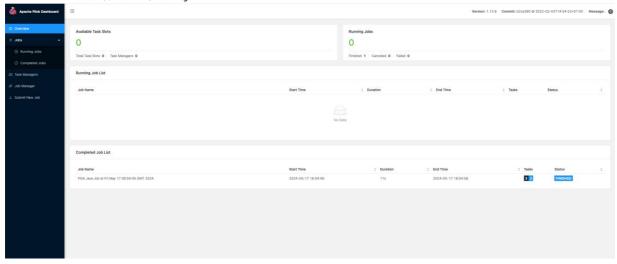
在yarn页面中有对应的任务



点击applicationmaster,由于没有配置DNS解析所以无法访问master,这里需要返回yarn页面复制网址粘贴到此处。



这里就能看到已经完成的job



四、Flink消费Kafka数据

1、实验介绍

对于实时处理,实际工作中的数据源一般都是使用Kafka。Flink提供了一个特有的Kafka连接器去读写Kafka topic的数据。本实验通过本地打jar包上传到Flink集群,去处理终端Kafka输入的数据。

2、实验目的

- ◆ 安装Kafka;
- ◆ 本地编辑代码读取Kafka数据,并且打成jar包;
- ◆ 将jar包上传到Flink集群运行。

3、实验步骤

3.1 安装Kafka

上传压缩包中的 kafka_2.12-1.0.2.tgz 安装包到master并解压到指定路径下。(如何将压缩包传到服务器再传到docker内部见实验二文档)

scp .\kafka_2.12-1.0.2.tgz <u>root@1.92.109.41:~/</u> tar -xzvf kafka_2.12-1.0.2.tgz

将Kafka安装包分发到各个dokcer中。

docker cp kafka_2.12-1.0.2 c4d7fb215e86:/root/ (容器编号记得修改)
docker cp kafka_2.12-1.0.2 8d9cecf44251:/root/
docker cp kafka_2.12-1.0.2 f79a87a959e5:/root/
docker cp kafka_2.12-1.0.2 84aa9ac2c578:/root/

配置**各个节点(4个节点都要弄哈)**的全局环境变量,在<mark>/etc/profile</mark> 文件中添加Kafka路径。(路径可以自己定义到别的,和上面一致就可以。)

```
root@slave3: ~
                       ×
if [ "${PS1-}" ]; then
 if [ "${BASH-}" ] && [ "$BASH" != "/bin/sh" ]; then
    if [ -f /etc/bash.bashrc ]; then
     . /etc/bash.bashrc
 else
    if [ "$(id -u)" -eq 0 ]; then
    else
    fi
 fi
fi
if [ -d /etc/profile.d ]; then
 for i in /etc/profile.d/*.sh; do
   if [ -r $i ]; then
   fi
 done
 unset i
export KAFKA_HOME=/root/kafka_2.12-3.5.0
export PATH=$KAFKA_HOME/bin:$PATH
```

```
#Kafka
export KAFKA_HOME=/root/kafka_2.12-1.0.2
export PATH=$KAFKA_HOME/bin:$PATH
source /etc/profile
```

进入各个节 Kafka 安装包的 config 目录,在 server.properties 配置文件中添加以下属性。

```
broker.id=1(id值唯一,与其他节点值不同)
host.name=master(对应节点改为对应主机名)
zookeeper.connect=master:2181,slave1:2181,slave2:2181,slave3:2181
```

验证是否安装成功(前提要启动ZooKeeper),在各个节点分别启动Kafka(注意执行该命令时,需要处于kafka的目录下)。

```
1 ./bin/kafka-server-start.sh ./config/server.properties
```

若遇到报错: Kafka报错ERROR Exiting Kafka due to fatal exception during startup Kafka报错ERROR Exiting Kafka due to fatal exception during startup error exiting kafka. (kafka.kafka\$)-CSDN博客

检查各个节点的JPS,当各个节点的jps都出现Kafka时说明安装成功。下图需要截屏作为得分点

```
[root@zj-2023140696 ~]# docker exec -it master bash
root@master:~# jps
20096 TaskManagerRunner
24929 Kafka
18915 StandaloneSessionClusterEntrypoint
22435 QuorumPeerMain
6180 FlinkYarnSessionCli
19236 TaskManagerRunner
13611 SecondaryNameNode
21584 FlinkYarnSessionCli
13841 ResourceManager
20914 TaskManagerRunner
6325 FlinkYarnSessionCli
14230 NodeManager
13368 NameNode
22296 YarnSessionClusterEntrypoint
25371 Jps
14431 DataNode
```

测试完成之后请务必关闭各节点的kafka进程!!!! 否则将会影响后续实验

使用命令 <mark>kafka-server-stop.sh</mark> 或者直接 <mark>kill</mark> kafka的进程号码

关闭之后输入 jps 检查 kafka 进程是否已经消失

```
root@master:~/kafka_2.12-3.5.0# kill -9 25061
root@master:~/kafka_2.12-3.5.0# jps
25568 Jps
452 SecondaryNameNode
1669 QuorumPeerMain
10472 TaskManagerRunner
24106 FlinkYarnSessionCli
1098 DataNode
7083 StandaloneSessionClusterEntrypoint
7662 TaskManagerRunner
11919 TaskManagerRunner
208 NameNode
22930 FlinkYarnSessionCli
692 ResourceManager
14711 TaskManagerRunner
1464 NodeManager
9083 TaskManagerRunner
13308 TaskManagerRunner
[1]+ Killed
                              ./bin/kafka-server-start.sh config/server.properties
```

3.2 创建maven工程

创建项目, 打开IDEA, 创建maven工程WordCount (具体步骤同实验一)。

3.3 添加Flink依赖

在pom文件中找到properties配置项,新增hadoop版本号。

```
docker cp kafka_2.12-1.0.2 c4d7fb215e86:/root/ (容器编号记得修改)
docker cp kafka_2.12-1.0.2 8d9cecf44251:/root/
docker cp kafka_2.12-1.0.2 f79a87a959e5:/root/
docker cp kafka_2.12-1.0.2 84aa9ac2c578:/root/
```

具体的pom文件内的依赖:

```
<groupId>org.example</groupId>
<artifactId>MyWordCount</artifactId>
<version>1.0-SNAPSHOT</version>
cproperties>
  <maven.compiler.source>8</maven.compiler.source>
  <maven.compiler.target>8</maven.compiler.target>
  project.build.sourceEncoding>UTF-8/project.build.sourceEncoding>
  <hadoop.version>3.3.6</hadoop.version>
</properties>
<dependencies>
  <dependency>
    <groupId>org.javatuples</groupId>
    <artifactId>javatuples</artifactId>
    <version>1.2</version>
  </dependency>
  <dependency>
    <groupId>log4j</groupId>
    <artifactId>log4j</artifactId>
    <version>1.2.17</version>
    <scope>provided</scope>
  </dependency>
  <dependency>
    <groupId>org.slf4j</groupId>
    <artifactId>slf4j-log4j12</artifactId>
    <version>1.7.7</version>
    <scope>runtime</scope>
  </dependency>
  <dependency>
    <groupId>org.apache.flink</groupId>
    <artifactId>flink-java</artifactId>
    <version>1.13.6</version>
    <scope>provided</scope>
  </dependency>
  <dependency>
    <groupId>org.apache.kafka</groupId>
    <artifactId>kafka 2.12</artifactId>
    <version>1.0.2</version>
  </dependency>
  <dependency>
    <groupId>org.apache.flink</groupId>
    <artifactId>flink-clients_2.11</artifactId>
    <version>1.13.6</version>
  </dependency>
  <dependency>
    <groupId>org.apache.kafka</groupId>
```

```
<artifactId>kafka-clients</artifactId>
      <version>1.0.2</version>
    </dependency>
    <dependency>
      <groupId>org.apache.flink</groupId>
      <artifactId>flink-streaming-scala_2.12</artifactId>
      <version>1.13.6</version>
    </dependency>
    <dependency>
      <groupId>org.apache.flink</groupId>
      <artifactId>flink-connector-kafka_2.11</artifactId>
      <version>1.13.6</version>
      <scope>provided</scope>
    </dependency>
    <dependency>
      <groupId>org.apache.flink</groupId>
      <artifactId>flink-connector-base</artifactId>
      <version>1.13.6</version>
    </dependency>
    <dependency>
      <groupId>org.apache.hadoop</groupId>
      <artifactId>hadoop-client</artifactId>
      <version>${hadoop.version}</version>
      <scope>provided</scope>
    </dependency>
    <dependency>
      <groupId>org.apache.hadoop</groupId>
      <artifactId>hadoop-common</artifactId>
      <version>${hadoop.version}</version>
    </dependency>
    <dependency>
      <groupId>org.apache.hadoop</groupId>
      <artifactId>hadoop-hdfs</artifactId>
      <version>${hadoop.version}</version>
    </dependency>
    <dependency>
      <groupId>junit</groupId>
      <artifactId>junit</artifactId>
      <version>RELEASE</version>
      <scope>test</scope>
    </dependency>
  </dependencies>
</project>
```

在pom文件中添加下列依赖并选择Maven->Reload project导入依赖包。

3.4 编写Flink代码

编写Flink读取Kafka数据的代码(可以在本机尝试运行代码正确后再打jar包)。

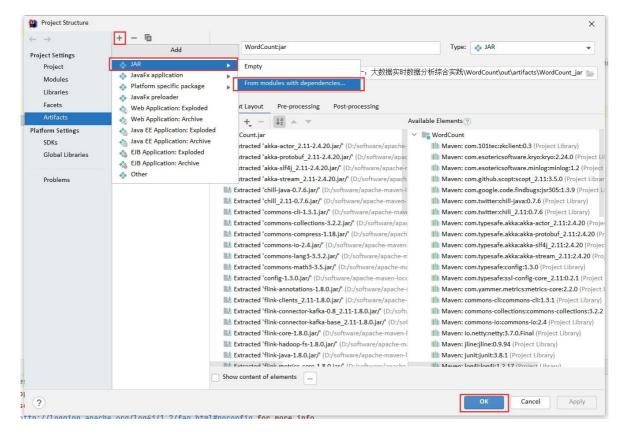


在项目的src/main/java目录下新建一个Flink_Kafka类,这个类名称大家可以自取,然后在该java文件中敲入以下代码

```
org.apache.flink.api.common.functions.FlatMapFunction;
public class Flink_Kafka {
         properties.setProperty("bootstrap.servers", "yty-2022140804-0801:9092"); //copy的时候记得修改对应的node节点名称
properties.setProperty("zookeeper.connect", "yty-2022140804-0801:2181"); //copy的时候记得修改对应的node节点名称
         FlinkKafkaConsumer<String> myconsumer = new FlinkKafkaConsumer<>>( lopic "test",new SimpleStringSchema(), properties);
         DataStream<String> dataStream = env.addSource(myconsumer);
         DataStream<Tuple2<String, Integer>> result = dataStream.flatMap(new MyFlatMapper()).keyBy( ...fields: 0).sum( positionToSum: 1);
            String[] words = s.split( regex: " ");
```

3.5 IDEA打包 (具体也可以见前面的实验报告)

在File->Project Structure中进行构建,点击Artifacts,点击上方的加号,选择JAR,From modules with dependencies,创建完成后点击OK。



选择Build->Build Artifacts->xxx.jar->Build, 然后将生成的jar包上传到master节点。

3.6 zk运行jar包

运行本次任务的时候,请务必保证上一章 Flink on Yarn模式 中 3.4节的Flink集群环境还存在就是下面这个命令,不需要再次执行,仅供大家回忆,如果你这个环境已经没有的话,请再次按照上一章3.4节给出的那四步操作,再次重新启动Flink集群环境即可

```
1 cd /root/flink
2 bin/yarn-session.sh -n 2 -jm 1024 -tm 1024 -d
```

由于我们需要用到KafKa自带的ZooKeeper。但是现在我们已经在四个节点启动了我们自己配置的 ZooKeeper,所以我们现在需要停掉node1节点的ZooKeeper

执行以下命令停止ZooKeeper (只用停掉node1节点的即可)

```
1 | zkServer.sh stop
```

然后启动KafKa自带的ZooKeeper。

```
cd /root/kafka_2.12-1.0.2

/bin/zookeeper-server-start.sh config/zookeeper.properties
```

```
[2024-05-16 14:18:35,952] INFO zookeeper.commitLogCount=500 (org.apache.zookeeper.server.ZKDatabase)
[2024-05-16 14:18:35,965] INFO zookeeper.snapshot.compression.method = CHECKED (org.apache.zookeeper.server.persistence.
SnapStream)
[2024-05-16 14:18:35,965] INFO Snapshotting: 0x0 to /tmp/zookeeper/version-2/snapshot.0 (org.apache.zookeeper.server.per
sistence.FileTxnSnapLog)
[2024-05-16 14:18:35,968] INFO Snapshot loaded in 16 ms, highest zxid is 0x0, digest is 1371985504 (org.apache.zookeeper
.server.ZKDatabase)
[2024-05-16 14:18:35,969] INFO Snapshotting: 0x0 to /tmp/zookeeper/version-2/snapshot.0 (org.apache.zookeeper.server.per
sistence.FileTxnSnapLog)
[2024-05-16 14:18:35,969] INFO Snapshot taken in 0 ms (org.apache.zookeeper.server.ZookeeperServer)
[2024-05-16 14:18:35,982] INFO PrepRequestProcessor (sid:0) started, reconfigEnabled=false (org.apache.zookeeper.server.
PrepRequestProcessor)
[2024-05-16 14:18:35,982] INFO zookeeper.request_throttler.shutdownTimeout = 10000 (org.apache.zookeeper.server.RequestT
hrottler)
[2024-05-16 14:18:36,000] INFO Using checkIntervalMs=60000 maxPerMinute=10000 maxNeverUsedIntervalMs=0 (org.apache.zooke
eper.server.ContainerManager)
[2024-05-16 14:18:36,000] INFO Zookeeper audit is disabled. (org.apache.zookeeper.server.persistence.FileTxnLog)
^[2024-05-16 14:20:51,190] INFO Creating new log file: log.1 (org.apache.zookeeper.server.persistence.FileTxnLog)
^[2024-05-16 14:20:51,190] INFO Creating new log file: log.1 (org.apache.zookeeper.server.persistence.FileTxnLog)
```

如果上图出现持续不停滚动的信息,说明启动失败

另外开启一个node01的终端,<mark>先进入到Kafka的安装目录下的config文件夹下</mark>,然后启动node01的 Kafka。(在bin目录下)

1 kafka-server-start.sh -daemon server.properties

```
[root@zj-2023140696 ~]# docker exec -it master bash
root@master:~# jps
20096 TaskManagerRunner
24929 Kafka
18915 StandaloneSessionClusterEntrypoint
22435 QuorumPeerMain
6180 FlinkYarnSessionCli
19236 TaskManagerRunner
13611 SecondaryNameNode
21584 FlinkYarnSessionCli
13841 ResourceManager
20914 TaskManagerRunner
6325 FlinkYarnSessionCli
14230 NodeManager
13368 NameNode
22296 YarnSessionClusterEntrypoint
25371 Jps
14431 DataNode
```

创建一个自定义名称为"test"的topic(这是node1节点启动的第二个终端),在终端启动一个生产者(注意先要进入到kafka的安装目录下再执行命令)。<mark>下图需要截图作为一处得分点</mark>

./bin/kafka-topics.sh --create --bootstrap-server master:2181 --replication-factor 1 -partitions 1 --topic test

./bin/kafka-console-producer.sh --broker-list master:9092 --topic test

另启动一个master的终端(也就是一共有三个master终端了),运行jar包。

```
1 [root@zyw-2021140807-0001 ~]# flink run -c [主类名] [jar包名]
```

主类名就是 在idea中 src/main/java 目录下新建的类的名称,示例中起的名称是 Flink_Kafka,示例的项目名称是WordCount,因此,最后执行的命令就是,下图需要截取作为一处得分点

flink run -c Flink Kafka WordCount.jar

```
restbactors of Elain kare. Flink_lefts. MylenGlouri.jar

| Comparison of Comparison of
```

若出现class无法引入的情况,参考:

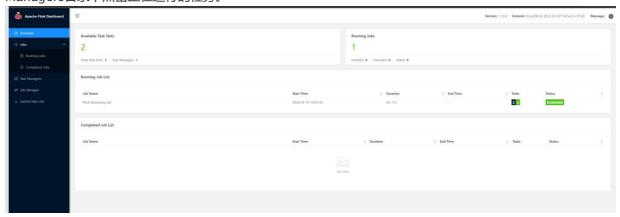
Flink案例系列2-提交到varn集群报错java.lang.NoClassDefFoundError FlinkKafkaConsumer flink yarn noclassdeffounderror kafka-CSDN博客

需要将相关的jar包 (从maven官网上下载) 传入到flink下面的lib文件夹内。

然后在生产者终端(也就是开启的第二个node1终端,那个终端最后输入的命令是<mark>kafka-console-producer.sh -- broker-list zyw-2021140807-0001:9092 --topic test,</mark>开的终端比较多,请不要弄混)中输入单词。

root@master:~/kafka_2.12-1.0.2# ./bin/kafka-console-producer.sh --broker-list master:9092 --topic test >123 321 211 21

根据前面Yarn Session(即上上张图片中红色框,框中显示的是某个节点,和一个端口号xxx,所以就 需要相对应节点对应的公网ip地址+xxx端口号)所在的机器公网ip访问Flink的Web管理界面。进入Task Managers目录下点击正在运行的任务。



进入后点击Stdout页面就可以看见读取到的Kafka数据了。下图需要截取作为一处得分点



整体的结构可以参考下图(20级张驰岳同学提供)



五、实验总结与分析

实验结束后应得到

- 1. Flink集群
- 2. Kafka集群
- 3. maven工程压缩包 (只包含代码及pom文件即可)

实验给分点:

注:以下截图需包含具体学号/IP信息,否则不得分。此外每个实验的输入单词不可以完全相同。

1. 第一部分: local模式部署安装

[root@zyw-2021140807-0001 log]# jps 17143 StandaloneSessionClusterEntrypoint 17619 TaskManagerRunner 17684 Jps

主节点jps查看当前进程。 (1分)

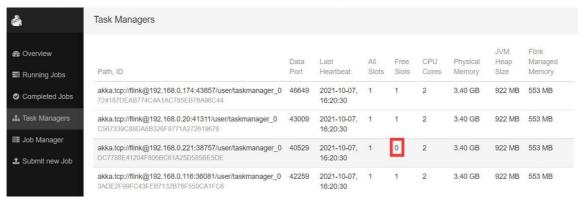
终端单词输入截图,Web管理界面或主节点终端输出out文件查看单词统计程序结果。(2分)

```
[root@zyw-2021140807-0001 log]# nc -lk 9000
qwe qwe qwe ^H^H^H^H^H flink harry harry hermin^Hone hermione
malfoy harry harry ronald flink malfoy
123 123 123 wer wer sdf

[root@zyw-2021140807-0001 -]# cd /home/modules/flink-1.8.0/log/
[root@zyw-2021140807-0001 log]# tail -200f flink-root-taskexecutor-0-zyw-2021140807-0001.out
qwe : 3
hermione : 1
hermione : 1
harry : 2
flink : 1
malfoy : 2
flink : 1
ronald : 1
harry : 3
123 : 3
sdf : 1
wer : 2
```

2. 第二部分: standalone模式部署安装

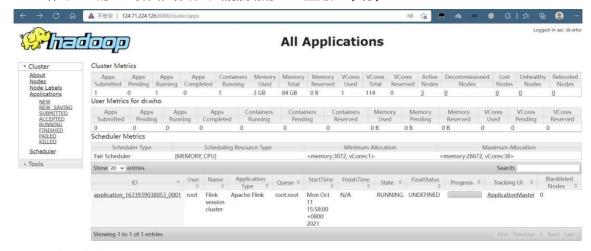
四个节点jps查看当前进程或Web管理界面查看Task Manager目录信息。 (1分)



终端单词输入截图, Web管理界面或对应节点终端输出out文件查看单词统计程序结果。 (2分)

```
[root@zyw-2021140807-0002 ~]# cd /home/modules/flink-1.8.0/log/
[root@zyw-2021140807-0002 log]# tail -200f flink-root-taskexecutor-0-zyw-2021140807-0002.out
flink : 4
nimbus : 2
123 : 4
zookeeper : 1
hadoop : 2
```

- 3. 第三部分: Flink on Yarn模式
 - ◇ 给出Yarn的Web界面,体现出当前启动的Flink应用。 (1分)



。任务提交并运行结果。(3分)

查看hdfs上的输出文件。 (2分)

```
[root@zyw-2021140807-0001 flink-1.8.0]# hdfs dfs -cat /flink_output/wordcount-result.txt
21/10/11 16:46:14 WARN util.NativeCodeLoader: Unable to load native-hadoop library for your platform... using built
in-java classes where applicable
flink 1
hadoop 1
hello 1
hive 1
spark 1
world 1
```

4. 第四部分: Flink消费Kafka数据

四个节点 jps出现Kafka进程截图。(2分)

```
[root@zyw-2021140807-0001 config]# kafka-server-start.sh -daemon server.properties
[root@zyw-2021140807-0001 config]# jps
10430 Kafka
7729 QuorumPeerMain
8381 NameNode
8597 SecondaryNameNode
8778 ResourceManager
10482 Jps
```

maven项目压缩包,包含代码和pom文件即可。(3分)

启动生产者、运行jar包、Web界面输出结果截图。(3分)

```
| Found Yarn properties file under /tmp/.yarn-properties-root. | 2021-18-12 15-47:26,660 INFO org.apache.flink.yarn.cli.FlinkYarnSessionCli | 2021-18-12 15-47:26,660 INFO org.apache.flink.yarn.cli.FlinkYarnSessionCli | 2021-18-12 15-47:26,160 INFO org.apache.flink.yarn.cli.FlinkYarnSessionCli | 2021-18-12 15-47:26,510 INFO org.apache.flink.yarn.cli.FlinkYarnSessionCli | 2021-18-12 15-47:26,500 INFO org.apache.flink.yarn.cli.FlinkYarnSessionCli | 2021-18-12 15-47:26,70 INFO org.apache.flink.yarn.cli.FlinkYarnSessionCli | 2021-18-12 15-47:26,500 INFO org.apache.flink.yarn.cli.FlinkYarnSessionCli | 2021-18-12 INFO org.apache.flink
```

